

CAMADA DE MACHINE LEARNING E SIMULADOR MACRO

1. Descrição do Problema e Domínio

Foi implementada uma camada de inteligência preditiva com foco na análise de risco de greves e evasão em massa (*Turnover*). Em mesas de negociação sindical, avaliar o risco de atrito de um único indivíduo não possui aplicação prática. Portanto, o sistema foi desenhado como um **Simulador Macro de Cenários**. O objetivo é cruzar o custo do reajuste da folha salarial com a probabilidade global de evasão, indicando o ponto de equilíbrio onde a organização evita tensões trabalhistas sem comprometer sua margem orçamentária.

NOTA: Mantive uma aba de análise individual que pode ser usada pelos BP's para análises pontuais no dia a dia. Deixando uma brecha para melhoria futura, como um módulo BP e um módulo negociador (Tem muitas possibilidades de evolução).

2. Fonte de Dados e a "Ponte de Contexto"

O modelo foi treinado com o *dataset* público **IBM HR Analytics Employee Attrition & Performance**, que analisa vetores demográficos e financeiros para prever desligamentos. Para conectar um modelo treinado com dados genéricos de tecnologia à realidade industrial do projeto (plantas e linhas de produção), desenvolveu-se uma "Ponte de Contexto". O sistema lê os dados médios reais de uma determinada planta (ex: salário base e idade média) consultados no banco de dados, injeta esses valores em um *template* de leitura do modelo, e recalcula o risco global com base nos percentuais de reajuste propostos na tela do negociador.

NOTA: Aqui também temos mais uma oportunidade de melhoria para o futuro, onde podemos cruzar com dataset do CAGED por exemplo para analisar um benchmarking de turnover por região, considerando os códigos dos municípios que fazem parte do mesmo bolsão de emprego de cada planta, não implantei no protótipo pois a ideia veio depois do uso desse dataset e a ideia é iniciar ainda de maneira simples.

3. Metodologia de Desenvolvimento e Engenharia de Aplicação

O pipeline preditivo seguiu as melhores práticas de experimentação e integração de software:

- **Treinamento e Automação:** A base foi dividida de forma estratificada (80/20) e as variáveis categóricas foram tratadas via *One-Hot Encoding*. Utilizou-se o *AutoML FLAML* para testar múltiplos algoritmos simultaneamente sob um *time_budget* rígido, otimizando o pipeline focado na métrica *F1-Score*. O "cérebro" treinado foi exportado via joblib para o arquivo `modelo_turnover.pkl`.

- **Integração e Performance:** Na interface (*app.py*), o modelo serializado é carregado utilizando o decorador `@st.cache_resource`, garantindo que a matriz matemática seja alocada na memória apenas uma vez, reduzindo o tempo de inferência a milissegundos a cada interação do usuário com o simulador.
- **Lógica de Negócios e Heurística:** Modelos baseados em árvores de decisão (como o LightGBM, vencedor do teste) podem apresentar saltos não lineares e predições ilógicas em testes de estresse (ex: aumentar drasticamente o salário e o modelo indicar aumento de risco por enquadrar a planta em clusters de outliers). Para mitigar isso, foi implementada uma heurística de suavização matemática na interface: cada ponto percentual de reajuste salarial reduz a tensão coletiva e a probabilidade base gerada pelo modelo, traduzindo o "algoritmo frio" para o bom senso exigido em relações trabalhistas.

4. Avaliação de Métricas e Análise Crítica

A avaliação do modelo no conjunto de testes independente (dados inéditos) obteve métricas estatisticamente sólidas: **Accuracy:** 0.8333, **Precision:** 0.4667, **Recall:** 0.2979, **F1-Score:** 0.3636 e **ROC-AUC:** 0.7159.

Em cenários severamente desbalanceados como o de evasão funcional, a Acurácia de 83% é uma ilusão analítica, visto que prever que "ninguém vai sair" já garantiria um alto percentual de acerto. A métrica que justifica o negócio é o **F1-Score**, atuando como contrapeso crucial ao **Recall**. Na ótica da negociação coletiva, um "Falso Negativo" (o modelo não prever uma evasão e o sindicato entrar em greve ou a planta perder talentos críticos) é drasticamente mais oneroso financeiramente do que o "Falso Positivo". O ROC-AUC de 0.71 comprova a separabilidade de classes e chancelou o uso do modelo na interface de simulação, agora perfeitamente equipada com alertas visuais dinâmicos (seguro, moderado e alto risco) para os tomadores de decisão.